Aprendizaje Automático Para La Clasificación De Pacientes Crónicos Con Comorbilidades

Autora: Paula Vecino Rodríguez
Tutora: Inmaculada Mora Jiménez
Co-Tutora: Cristina Soguero Ruíz

Universidad Rey Juan Carlos

ETSIT

ETSIT

Objetivo

Evaluación, en términos de prestaciones, de métodos basados en el aprendizaje automático que permitan predecir el estado de salud de pacientes crónicos.

1. Introducción
2. Métodos de clasificación multi-clase y multi-etiqueta
3. Experimentos y resultados
4. Conclusiones y líneas futuras

ETSIT

Introducción

1. Pacientes crónicos. Situación en España
2. Sistema de clasificación poblacional
3. Análisis descriptivo de la base de datos

ETSIT

Pacientes crónicos. Situación en España

- Según la OMS (Organización Mundial de la Salud): *enfermedad de larga duración, normalmente de evolución lenta, y cuya curación no se puede prever.*

- Factores de riesgo: envejecimiento; consumo alto de alcohol, tabaco y sal; e inactividad física, entre otros.

- 42% de la población adulta de España, tiene una o varias patologías crónicas.

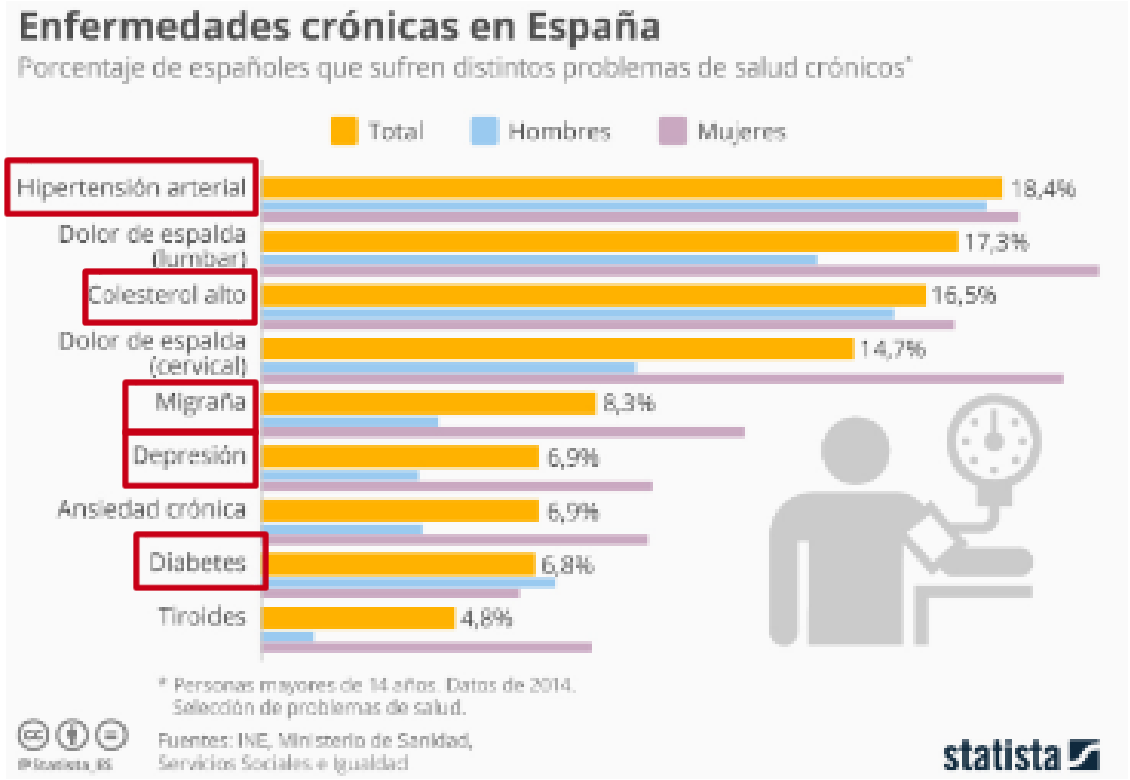

Sistemas de clasificación de pacientes

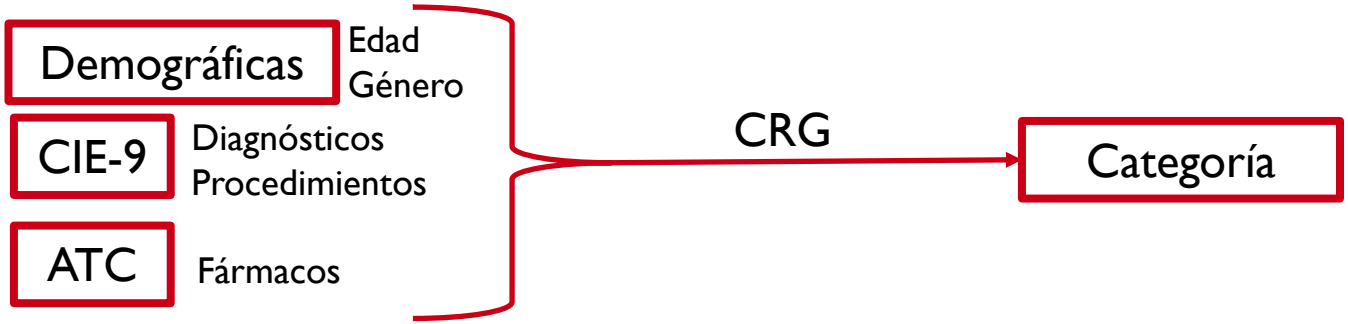

CRG base	Descripción del CRG	Pacientes HUF
1000	Sanos	46.835
5192	Hipertensión	12.447
5424	Diabetes	2.166
6144	Diabetes - Hipertensión	3.179
7071	Diabetes - Hipertensión - Otra Enfermedad Crónica Dominante	547

- Nuestra base de datos la componen pacientes pertenecientes al Hospital Universitario de Fuenlabrada en el periodo 2012.

		Diagnósticos				Fármacos
Edad	Género	001-999 Enfermedades	V01-V89 Códigos V	E000-E999 Códigos E	M888-M997 Códigos M	A01AA-V30ZZ ATC

- 2265 características: binarias o basadas en la ocurrencia.

ETSIT

Análisis descriptivo de la base de datos

- Análisis descriptivo de los CRG utilizados en este trabajo:

	CRG1000	CRG5192	CRG5424	CRG6144	CRG7071
Pacientes en el CRG	46835	12447	2166	3179	547
Mujeres	24649	6464	743	1424	305
Hombres	22186	5983	743	1755	242
Códigos CIE-9 Totales	1517				
Códigos CIE-9 diferentes por paciente en cada CRG	2,70	4,84	4,31	6,01	9,52
Mujeres	2,90	5,57	4,97	6,98	9,93
Hombres	3,02	4,03	3,95	5,22	8,98
Valor medio de códigos CIE-9 por paciente en cada CRG	4,27	12,96	13,28	18,74	32,15
Mujeres	4,70	14,96	14,34	21,78	33,54
Hombres	4,79	10,79	12,28	16,27	30,39
Código ATC Totales	746				
Códigos ATC diferentes por paciente en cada CRG	2,12	5,71	5,30	9,11	14,94
Mujeres	2,16	6,11	5,65	10,42	15,65
Hombres	1,44	7,34	5,11	8,01	14,04
Valor medio de códigos ATC por paciente en cada CRG	2,95	22,01	21,81	50,07	86,44
Mujeres	3,01	23,59	23,25	57,29	90,57
Hombres	2,01	28,28	21,04	44,02	81,22

ETSIT

Métodos de clasificación multi-clase y multi-etiqueta

1. Introducción
2. Algoritmos de clasificación
3. Evaluación de prestaciones

Introducción

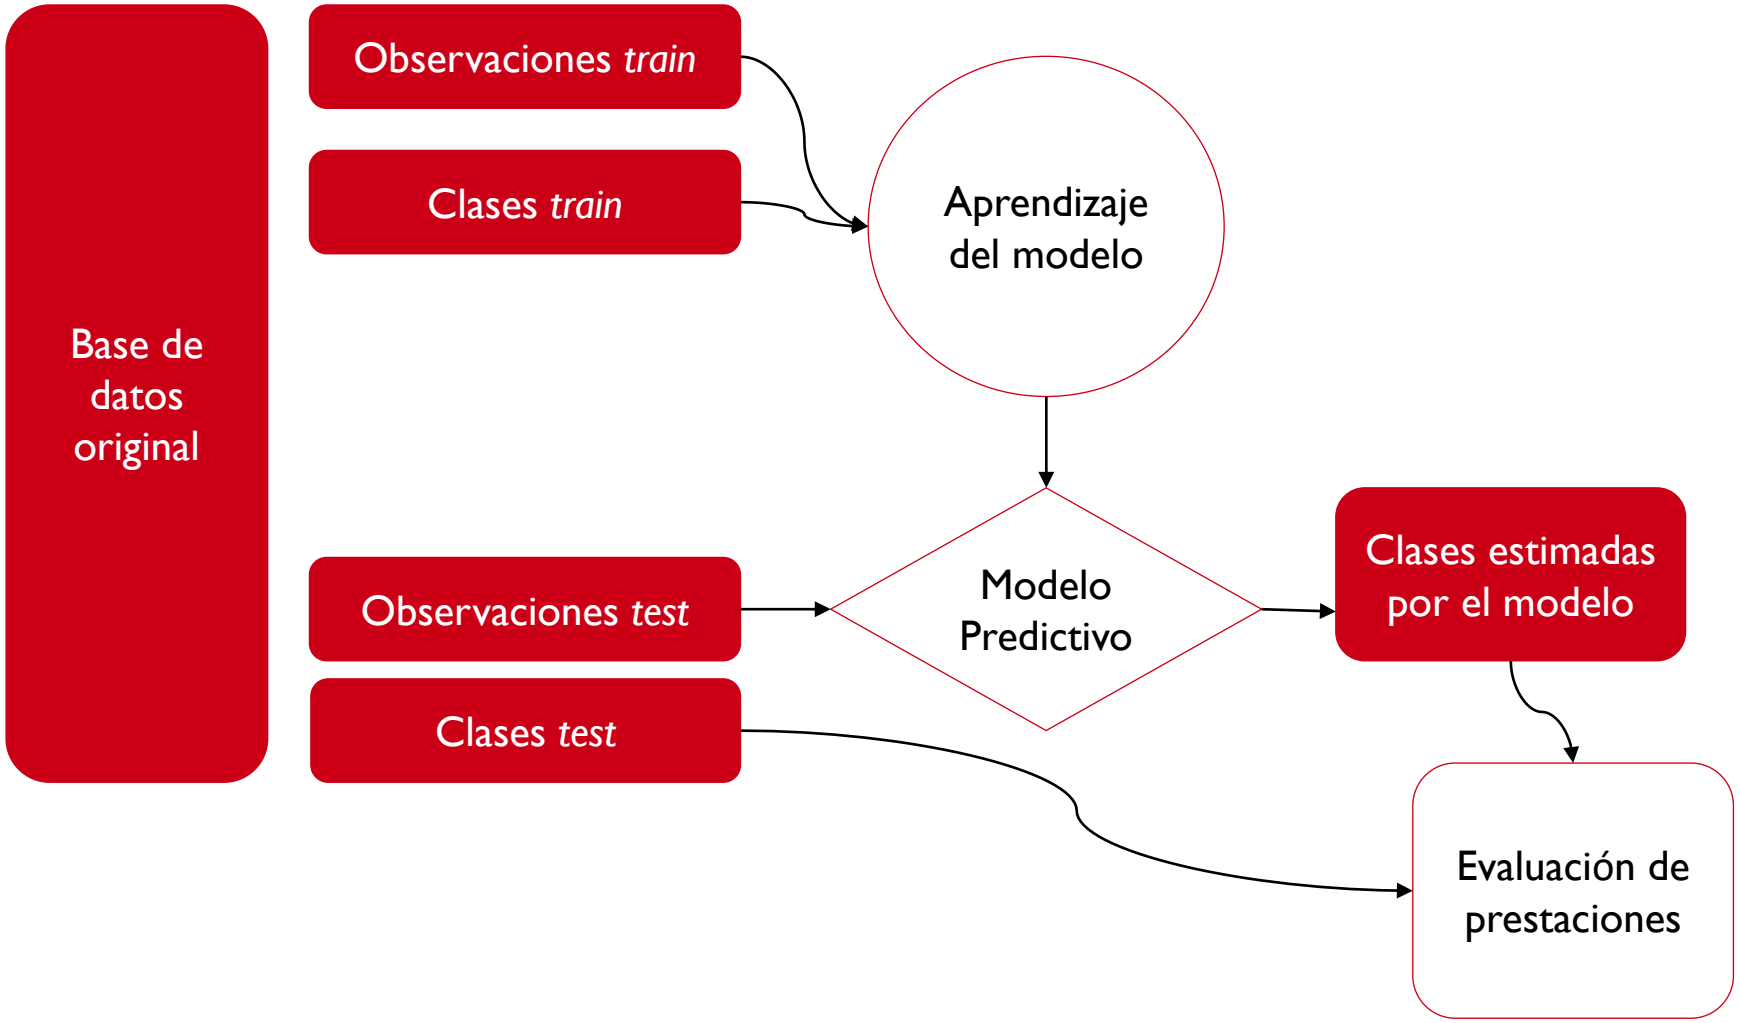

ETSIT

Objetivo y retos

- Objetivo: modelo predictivo construido tenga capacidad clasificar adecuadamente casos nunca vistos.
- Se propone abordar el modelo del diseño bajo dos enfoques: multi-clase (MC) y multi-etiqueta (ME).
- Retos:
  - Desbalanceo en las categorías.
  - Gran número de características con respecto conjunto de casos disponibles.

Algoritmos de clasificación

Lineales

- Regresión Logística Multinominal (MC)
- Máquinas de Vectores Soporte Lineal (MC y ME)

No lineales

- Máquinas de Vectores Soporte No Lineal (MC y ME)
- K *Nearest Neighbour* (MC y ME)
- Árboles de decisión (MC y ME)
- *Random Forest* (MC y ME)
- Perceptrón Multicapa (MC y ME)

Evaluación de prestaciones

- Tasa de acierto multi-clase.

$$accuracy = \frac{tp + tn}{tp + fp + tn + fn}$$

		Clase estimada		
		C1	**C2**	**C3**
Clase *test*	**C1**	tp	fn	fn
	C2	fp	tn	tn
	C3	fp	tn	tn

- Tasa de acierto multi-etiqueta.

$$accuracy = \frac{1}{n}\sum_{i=1}^{n}\frac{Y_i \bigcap P_i}{Y_i \bigcup P_i}$$

$$Y = \{Y_1, Y_2, \ldots, Y_i\}\ i = 1 \ldots m$$

$$P = \{P_1, P_2, \ldots, P_i\}\ i = 1 \ldots m$$

ETSIT

Experimentos y resultados.

1. Experimentos
2. Procedimiento
3. Resultados

Experimentos

- Clasificación multi-etiqueta y multi-clase.

	Multi-clase	Multi-etiqueta		
CRG	Clase	Hipertensión	Diabetes	Comorbilidades
CRG1000	0	0	0	0
CRG5192	1	1	0	0
CRG5424	2	0	1	0
CRG6144	3	1	1	0
CRG7071	4	1	1	1

- Dos escenarios:
  - Escenario 1 - Pacientes sanos y crónicos
  - Escenario 2 - Pacientes crónicos.
- Balanceo de observaciones: submuestreo sobre la clase minoritaria (CRG7071), creando 50 subconjuntos.
  - Escenario 1 - 2735 pacientes
  - Escenario 2 - 2188 pacientes
- Conjunto de *train* (80%) y *test* (20%).
- Características binarias o basadas en ocurrencia.
- Selección de las 100 características.
  - FS1 - Frecuencia
  - FS2 - Prueba F-Fisher
  - FS3 - *Random Forest*

Procedimiento

1. Carga 50 subconjuntos de *train* y *test* junto con las características seleccionadas.

Para cada subconjunto de *train*:

- **2.** Filtrado de los datos duplicados y normalización del conjunto de *train*.
- **3.** Búsqueda de los mejores parámetros libres con validación cruzada.

4. Ajuste del modelo con los mejores parámetros .

5. Normalización del conjunto de *test.*

6. Evaluación de los 50 subconjuntos de test con el diseño

Resultados

			Pacientes sanos y crónicos		Pacientes crónicos	
Clasificación	**Forma de las caracterisitcas**	**Selección de caracteristicas**	**Algoritmo**	**Tasa de acierto**	**Algoritmo**	**Tasa de acierto**
Multi-clase	Ocurrencia	Frecuencia	Random Forest	85,3(1,4)%	Random Forest	83,2(1,6)%
		F-Fisher	Regresión Logisitica Multinominal	**88,8(1,1)%**	Linear SVM	**88,6(1,4)%**
		Random Forest	Random Forest	86,0(1,4)%	Regresión Logisitica Multinominal	84,9(1,7)%
	Binarias	Frecuencia	No Linear SVM	85,8(1,4)%	No Linear SVM	83,7(1,6)%
		F-Fisher	No Linear SVM	**91,6(1,2)%**	No Linear SVM	**90,9(1,2)%**
		Random Forest	No Linear SVM	88,9(1,3)%	No Linear SVM	87,7(1,4)%
Multi-etiqueta	Ocurrencia	Frecuencia	Linear SVM OneVsRest	85,2(1,52)%	Linear SVM Label Powerset	82,7(1,9)%
			Random Forest	84,7(1,4)%	Random Forest	82,5(1,8)%
		F-Fisher	Linear SVM OneVsRest	**89,5(1,3)%**	Linear SVM Label Powerset	**88,6(1,5)%**
			Random Forest	**85,7(1,2)%**	Random Forest	**84,2(1,7)%**
		Random Forest	Linear SVM OneVsRest	87,7(1,4)%	Linear SVM Label Powerset	86,4(1,9)%
			Random Forest	85,5(1,3)%	Random Forest	82,7(1,7)%
	Binarias	Frecuencia	No Linear SVM Label Powerset	85,6(1,3)%	No Linear SVM Label Powerset	84,0(1,4)%
			MLP	84,4(1,4)%	MLP	81,7(1,7)%
		F-Fisher	Linear SVM OneVsRest	**91,2(1,0)%**	No Linear SVM Label Powerset	**90,3(1,2)%**
			MLP	**90,3(1,1)%**	MLP	**88,3(1,5)%**
		Random Forest	Linear SVM OneVsRest	89,1(1,1)%	No Linear SVM Label Powerset	88,6(1,0)%
			MLP	87,7(1,5)%	MLP	86,8(1,2)%

Resultados

- Resultados sobre la relevancia de los distintos tipos de características.
- Mejor configuración: características binarias y selección de características basadas en la prueba F-Fisher.

			Pacientes sanos y crónicos		Pacientes crónicos	
			Número caracterisitcas	Tasa de acierto	Número caracterisitcas	Tasa de acierto
Perceptrón Multicapa	Multi-clase	Género + Edad + CIE-9 + ATC	102	90,3(1,0)%	102	88,0(1,5)%
		CIE-9 + ATC	100	72,8(7,5)%	100	98,0(1,4)%
		CIE-9	31	54,0(9,4)%	30	32,8(11,2)%
		ATC	69	74,2(8,8)%	70	72,8(7,5)%
		Género + Edad	2	31,8(2,0)%	2	22,1(2,0)%
	Multi-etiqueta	Género + Edad + CIE-9 + ATC	102	90,3(1,1)%	102	88,3(1,5)%
		CIE-9 + ATC	100	89,5(1,2)%	100	88,1(1,5)%
		CIE-9	33	45,5(19,6)%	34	55,1(6,3)%
		ATC	67	82,0(3,5)%	66	82,3(1,5)%
		Género + Edad	2	25,1(5,3)%	2	30,4(2,5)%

Conclusiones y líneas futuras

1. Conclusiones
2. Líneas futuras

ETSIT

Conclusiones

- Más códigos CIE-9 y ATC para los CRG con más de una cronicidad.
- Mejor método de selección de características: prueba F-Fisher.
- Mejores tasas de acierto cuando consideramos la base de datos de pacientes sanos y crónicos.
- Para características binarias, elección de modelos no lineales; para características basadas en ocurrencia, elección de modelos lineales.
- Para métodos de transformación de problema, resultados en multi-clase y multi-etiqueta similares.
- Para los modelos adaptados, resultados ligeramente mejores (0,3%) para multi-etiqueta. El número de pacientes considerados nos limita el aprendizaje de los modelos propuestos.

ETSIT

Líneas futuras

- Aumentar la población de estudio para que aumente la clase minoritaria y así poder tener subconjuntos de *train* mayores para entrenar los algoritmos.
- Estudiar algoritmos que no beneficien a la clase mayoritaria para no realizar balanceo de observaciones.
- Trabajar la visualización para que el personal clínico no vea sólo una 'caja negra'.
- Entrenar los algoritmos en algún servicio de *cluster* de servidores como *Amazon Web Services*.

Muchas gracias por su atención.

ETSIT

Universidad Rey Juan Carlos

VECINO RODRIGUEZ PAULA - 70252704D

Firmado digitalmente por VECINO RODRIGUEZ PAULA - 70252704D
Fecha: 2019.11.07 00:51:01 +01'00'